Práctica 1 AED

Introducción a la Ciencia de Datos. Máster en Ciencia de Datos- UV

Francesc Oliver Catany

2026-10-20

Índice

1. Introducción **1**
1.1. Primer apartado: fichero DFP1_11122015 124700.csv 1
1.2. Importación del fichero 2
1.3. Inspección de los datos 2

2. Fichero *Transactions from a Bakery* (Kaggle) **3**
2.1. Importación del fichero 3
2.2. Inspección de los datos 3

3. Fichero SPSS PsychBike.sav **5**
3.1. Importación del fichero 5
3.2. Inspección de los datos 5

4. Fichero data iris.zip **6**
4.1. Descomprimir el fichero 6

5. Fichero data iris.data **6**
5.1. Importación del fichero 6
5.2. Inspección de los datos 7

6. Fichero JSON FileCodificado.json **8**
6.1. Importar el fichero FileCodificado.json 8

7. Fichero JSON iris_json.json **11**
7.1. Importar el fichero iris_json.json 11
7.2. 8.3 exportar datos en formato JSON 12

1. Introducción

En este documento se va a realizar la práctica 1 de Análisis exploratorio de datos.

1.1. Primer apartado: fichero DFP1_11122015 124700.csv

Empezamos cargando los datos de este primer csv. Los cargamos con la función import Dataset de Rstudio. Cuando usamos la función base, nos detecta solo que esta separado por tabuladores y no coloca correctamente las columnas. En cambio usando readr tenemos que ponerlo a mano, porque por defecto usa como separador las comas. Además cambia el tipo de datos que usan. AL usar la versión base tenemos la hora en versión chr, que es un string. En cambio en readr usa un formato de horas llamado hms.

1.2. Importación del fichero

```
#versión base
Deposito <-read.csv("./data/DFP1_11122015 124700.csv",  stringsAsFactors = F, sep="\t")

#Lo transformo de tipo chr a tipo date, así lo almaceno de manera correcta
Deposito$FECHA <- as.POSIXlt(Deposito$FECHA, format="%d/%m/%Y")

library(hms)

Deposito$HORA <- as.hms(Deposito$HORA)
```

```
## Warning: `as.hms()` was deprecated in hms 1.2.0.
## i Please use `as_hms()` instead.
## This warning is displayed once per session.
## Call `lifecycle::last_lifecycle_warnings()` to see where this warning was
## generated.
```

```
# Creo la carpeta dentro de data
dir.create("./data/results", showWarnings = FALSE)

# Guardar el objeto Deposito
save(Deposito, file = "./data/results/Deposito.RData")
```

1.3. Inspección de los datos

LA función string nos devuelve un resumen escrito de las variables y los tipos en el dataframe.

```
str(Deposito)
```

```
## 'data.frame':    8887 obs. of  5 variables:
##  $ FECHA            : POSIXlt, format: "2015-12-11" "2015-12-11" ...
##  $ HORA             : 'hms' num  12:47:02 12:47:02 12:47:02 12:47:03 ...
##   ..- attr(*, "units")= chr "secs"
##  $ Altura           : num  138 138 138 138 138 ...
##  $ Combinacion_Canya: num  2 2 2 2 2 2 2 2 2 2 ...
##  $ Temperatura      : num  14.6 14.6 14.6 14.6 14.6 14.6 14.6 14.6 14.6 14.6 ...
```

LA función head nos devuelve una muestra de los primeros elementos del dataframe.

```
head(Deposito)
```

```
##        FECHA     HORA Altura Combinacion_Canya Temperatura
## 1 2015-12-11 12:47:02 137.81                 2        14.6
## 2 2015-12-11 12:47:02 137.81                 2        14.6
## 3 2015-12-11 12:47:02 137.81                 2        14.6
## 4 2015-12-11 12:47:03 137.81                 2        14.6
## 5 2015-12-11 12:47:03 137.81                 2        14.6
## 6 2015-12-11 12:47:03 137.81                 2        14.6
```

La función head nos devuelve una muestra de los ultimos elementos del dataframe.

```
tail(Deposito)
```

```
##           FECHA     HORA Altura Combinacion_Canya Temperatura
## 8882 2015-12-11 13:49:41 949.13                 2        14.7
## 8883 2015-12-11 13:49:41 949.13                 2        14.7
## 8884 2015-12-11 13:49:41 949.13                 2        14.7
```

```
## 8885 2015-12-11 13:49:41 949.13                2        14.7
## 8886 2015-12-11 13:49:41 949.13                2        14.7
## 8887 2015-12-11 13:49:42 949.13                2        14.7
```

La función summary nos muestra algunas medidas de resumen de cada variable, como los valores mínimo y máximo o los cuartiles.

```
summary(Deposito)
```

```
##      FECHA                HORA              Altura       Combinacion_Canya
##  Min.   :2015-12-11   Length:8887       Min.   : 137.8   Min.   :1
##  1st Qu.:2015-12-11   Class1:hms        1st Qu.: 400.9   1st Qu.:1
##  Median :2015-12-11   Class2:difftime   Median : 953.1   Median :2
##  Mean   :2015-12-11   Mode  :numeric    Mean   : 785.8   Mean   :2
##  3rd Qu.:2015-12-11                     3rd Qu.:1079.0   3rd Qu.:3
##  Max.   :2015-12-11                     Max.   :1089.1   Max.   :3
##   Temperatura
##  Min.   :14.40
##  1st Qu.:14.50
##  Median :14.60
##  Mean   :14.57
##  3rd Qu.:14.60
##  Max.   :14.70
```

2. Fichero *Transactions from a Bakery* (Kaggle)

2.1. Importación del fichero

```
library(readr)
bakery_sales_revised <- read_csv("data/bakery_sales_revised.csv")
```

```
## Rows: 20507 Columns: 5
## -- Column specification --------------------------------------------------------
## Delimiter: ","
## chr (4): Item, date_time, period_day, weekday_weekend
## dbl (1): Transaction
##
## i Use `spec()` to retrieve the full column specification for this data.
## i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

```
View(bakery_sales_revised)


# Guardar el objeto bakery
save(bakery_sales_revised, file = "./data/results/BreadBasket.RData")
```

2.2. Inspección de los datos

```
str(bakery_sales_revised)
```

```
## spc_tbl_ [20,507 x 5] (S3: spec_tbl_df/tbl_df/tbl/data.frame)
##  $ Transaction    : num [1:20507] 1 2 2 3 3 3 4 5 5 5 ...
##  $ Item           : chr [1:20507] "Bread" "Scandinavian" "Scandinavian" "Hot chocolate" ...
##  $ date_time      : chr [1:20507] "10/30/2016 9:58" "10/30/2016 10:05" "10/30/2016 10:05" "10/30/201
##  $ period_day     : chr [1:20507] "morning" "morning" "morning" "morning" ...
```

```
##  $ weekday_weekend: chr [1:20507] "weekend" "weekend" "weekend" "weekend" ...
##  - attr(*, "spec")=
##   .. cols(
##   ..   Transaction = col_double(),
##   ..   Item = col_character(),
##   ..   date_time = col_character(),
##   ..   period_day = col_character(),
##   ..   weekday_weekend = col_character()
##   .. )
##  - attr(*, "problems")=<externalptr>
```

```
head(bakery_sales_revised)
```

```
## # A tibble: 6 x 5
##   Transaction Item          date_time        period_day weekday_weekend
##         <dbl> <chr>         <chr>            <chr>      <chr>
## 1           1 Bread         10/30/2016 9:58  morning    weekend
## 2           2 Scandinavian  10/30/2016 10:05 morning    weekend
## 3           2 Scandinavian  10/30/2016 10:05 morning    weekend
## 4           3 Hot chocolate 10/30/2016 10:07 morning    weekend
## 5           3 Jam           10/30/2016 10:07 morning    weekend
## 6           3 Cookies       10/30/2016 10:07 morning    weekend
```

```
tail(bakery_sales_revised)
```

```
## # A tibble: 6 x 5
##   Transaction Item         date_time      period_day weekday_weekend
##         <dbl> <chr>        <chr>          <chr>      <chr>
## 1        9682 Tacos-Fajita 4/9/2017 14:32 afternoon  weekend
## 2        9682 Coffee       4/9/2017 14:32 afternoon  weekend
## 3        9682 Tea          4/9/2017 14:32 afternoon  weekend
## 4        9683 Coffee       4/9/2017 14:57 afternoon  weekend
## 5        9683 Pastry       4/9/2017 14:57 afternoon  weekend
## 6        9684 Smoothies    4/9/2017 15:04 afternoon  weekend
```

```
summary(bakery_sales_revised)
```

```
##   Transaction       Item            date_time          period_day
##  Min.   :   1   Length:20507       Length:20507       Length:20507
##  1st Qu.:2552   Class :character   Class :character   Class :character
##  Median :5137   Mode  :character   Mode  :character   Mode  :character
##  Mean   :4976
##  3rd Qu.:7357
##  Max.   :9684
##  weekday_weekend
##  Length:20507
##  Class :character
##  Mode  :character
##
##
##
```

3. Fichero SPSS PsychBike.sav

3.1. Importación del fichero

```
library(haven)
psych_bike <- read_sav("./data/PsychBike.sav")

# Guardar el objeto
save(psych_bike, file = "./data/results/PsychBike.RData")
```

3.2. Inspección de los datos

```
str(psych_bike)
```

```
## tibble [2,355 x 6] (S3: tbl_df/tbl/data.frame)
##  $ vehicle           : dbl+lbl [1:2355] 1, 5, 2, 1, 4, 1, 2, 1, 4, 7, 2, 3, 1, 1, 1, 2, 1, 2,...
##    ..@ format.spss: chr "F11.0"
##    ..@ labels     : Named num [1:7] 1 2 3 4 5 6 7
##    .. ..- attr(*, "names")= chr [1:7] "car" "LGV" "SUV" "bus" ...
##  $ Colour            : dbl+lbl [1:2355]  1,  2,  1, 99,  9,  3,  4,  2,  2, 99,  4,  4,  1,  ...
##    ..@ format.spss: chr "F11.0"
##    ..@ labels     : Named num [1:8] 1 2 3 4 5 6 9 99
##    .. ..- attr(*, "names")= chr [1:8] "blue" "red" "silver/grey" "white" ...
##  $ hour              : 'hms' num [1:2355] 16:00:00 16:00:00 16:00:00 16:00:00 ...
##   ..- attr(*, "units")= chr "secs"
##   ..- attr(*, "format.spss")= chr "TIME11.2"
##  $ helmet            : num [1:2355] 0 0 0 0 0 0 1 1 1 1 ...
##   ..- attr(*, "format.spss")= chr "F11.0"
##  $ Distance_from_kerb: num [1:2355] 0.5 0.5 0.5 0.5 0.5 0.5 1 1 1 1 ...
##   ..- attr(*, "label")= chr "Distance from kerb"
##   ..- attr(*, "format.spss")= chr "F11.1"
##  $ Passing_distance  : num [1:2355] 1.864 0.748 1.567 1.39 1.294 ...
##   ..- attr(*, "label")= chr "Passing distance"
##   ..- attr(*, "format.spss")= chr "F11.3"
```

```
head(psych_bike)
```

```
## # A tibble: 6 x 6
##   vehicle   Colour           hour   helmet Distance_from_kerb Passing_distance
##   <dbl+lbl> <dbl+lbl>        <time>  <dbl>               <dbl>            <dbl>
## 1 1 [car]    1 [blue]        16:00       0                 0.5            1.86
## 2 5 [HGV]    2 [red]         16:00       0                 0.5            0.748
## 3 2 [LGV]    1 [blue]        16:00       0                 0.5            1.57
## 4 1 [car]   99 [unknown]     16:00       0                 0.5            1.39
## 5 4 [bus]    9 [other]       16:00       0                 0.5            1.29
## 6 1 [car]    3 [silver/grey] 16:00       0                 0.5            1.26
```

```
tail(psych_bike)
```

```
## # A tibble: 6 x 6
##   vehicle   Colour          hour   helmet Distance_from_kerb Passing_distance
##   <dbl+lbl> <dbl+lbl>       <time>  <dbl>               <dbl>            <dbl>
## 1 2 [LGV]   9 [other]       10:00       1                1.25            1.10
## 2 1 [car]   3 [silver/grey] 10:00       1                1.25            1.01
## 3 1 [car]   2 [red]         10:00       1                1.25            0.922
```

```
## 4 5 [HGV]   4 [white]       10:00       1               1.25            0.564
## 5 1 [car]   1 [blue]        10:00       1               1.25            0.65
## 6 1 [car]   6 [green]       10:00       1               1.25            0.781
```

```
summary(psych_bike)
```

```
##     vehicle          Colour           hour              helmet
##  Min.   :1.000   Min.   : 1.000   Length:2355       Min.   :0.0000
##  1st Qu.:1.000   1st Qu.: 1.000   Class1:hms        1st Qu.:0.0000
##  Median :1.000   Median : 3.000   Class2:difftime   Median :0.0000
##  Mean   :1.634   Mean   : 3.556   Mode  :numeric    Mean   :0.4879
##  3rd Qu.:2.000   3rd Qu.: 4.000                     3rd Qu.:1.0000
##  Max.   :7.000   Max.   :99.000                     Max.   :1.0000
##  Distance_from_kerb Passing_distance
##  Min.   :0.2500     Min.   :0.144
##  1st Qu.:0.2500     1st Qu.:1.053
##  Median :0.5000     Median :1.279
##  Mean   :0.6702     Mean   :1.314
##  3rd Qu.:1.0000     3rd Qu.:1.540
##  Max.   :1.2500     Max.   :3.537
```

4. Fichero data iris.zip

Usamos esta función para descargar el fichero directamente desde la web.

```
# Descargar el archivo ZIP
download.file(
  url = "https://archive.ics.uci.edu/static/public/53/iris.zip",
  destfile = "./data/iris.zip",
  mode = "wb"
)
```

4.1. Descomprimir el fichero

Esta función nos descomprime el fichero el exdir.

```
unzip("./data/iris.zip", exdir = "./data")
```

5. Fichero data iris.data

5.1. Importación del fichero

```
#le añado directament los nombres
iris <- read.table("./data/iris.data",
                   sep = ",",
                   header = FALSE,
                   col.names = c("sepal length",
                                 "sepal width",
                                 "petal length",
                                 "petal width",
                                 "class"),
                   check.names = FALSE)
```

```
save(iris, file = "./data/results/iris.RData")
```

5.2. Inspección de los datos

```
str(iris)
```

```
## 'data.frame':    150 obs. of  5 variables:
##  $ sepal length: num  5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
##  $ sepal width : num  3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1 ...
##  $ petal length: num  1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ...
##  $ petal width : num  0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ...
##  $ class       : chr  "Iris-setosa" "Iris-setosa" "Iris-setosa" "Iris-setosa" ...
```

```
head(iris)
```

```
##   sepal length sepal width petal length petal width       class
## 1          5.1         3.5          1.4         0.2 Iris-setosa
## 2          4.9         3.0          1.4         0.2 Iris-setosa
## 3          4.7         3.2          1.3         0.2 Iris-setosa
## 4          4.6         3.1          1.5         0.2 Iris-setosa
## 5          5.0         3.6          1.4         0.2 Iris-setosa
## 6          5.4         3.9          1.7         0.4 Iris-setosa
```

```
tail(iris)
```

```
##     sepal length sepal width petal length petal width          class
## 145          6.7         3.3          5.7         2.5 Iris-virginica
## 146          6.7         3.0          5.2         2.3 Iris-virginica
## 147          6.3         2.5          5.0         1.9 Iris-virginica
## 148          6.5         3.0          5.2         2.0 Iris-virginica
## 149          6.2         3.4          5.4         2.3 Iris-virginica
## 150          5.9         3.0          5.1         1.8 Iris-virginica
```

```
summary(iris)
```

```
##   sepal length    sepal width     petal length    petal width
##  Min.   :4.300   Min.   :2.000   Min.   :1.000   Min.   :0.100
##  1st Qu.:5.100   1st Qu.:2.800   1st Qu.:1.600   1st Qu.:0.300
##  Median :5.800   Median :3.000   Median :4.350   Median :1.300
##  Mean   :5.843   Mean   :3.054   Mean   :3.759   Mean   :1.199
##  3rd Qu.:6.400   3rd Qu.:3.300   3rd Qu.:5.100   3rd Qu.:1.800
##  Max.   :7.900   Max.   :4.400   Max.   :6.900   Max.   :2.500
##     class
##  Length:150
##  Class :character
##  Mode  :character
##
##
##
```

6. Fichero JSON FileCodificado.json

6.1. Importar el fichero FileCodificado.json

Es importante usar el simplifyvector, ya que si no lo usas te devuelve una cadena de caracteres muy larga, en vez de un dataframe.

```
library(jsonlite)

file_codificado <- read_json("./data/FileCodificado.json", simplifyVector = T)
```

```
str(file_codificado)
```

```
## 'data.frame':    83 obs. of  22 variables:
##  $ Carburante             : int  1 1 1 1 1 1 1 1 1 1 ...
##  $ Potencia               : int  60 60 60 60 60 60 60 60 60 60 ...
##  $ Servicio_Vehiculo      : chr  "B00" "B00" "B00" "B00" ...
##  $ Actividad_Vehiculo     : chr  "D" "D" "D" "D" ...
##  $ GAMA                   : chr  "UTILITARIO" "UTILITARIO" "UTILITARIO" "UTILITARIO" ...
##  $ Unidades_Matriculadas  : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ Localidad_definitiva   : chr  "ALGECIRAS" "ALGECIRAS" "ALGECIRAS" "ALGECIRAS" ...
##  $ Provincia_definitiva   : chr  "CADIZ" "CADIZ" "CADIZ" "CADIZ" ...
##  $ Codigo_Postal          : num  0.0297 0.0297 0.0297 0.0297 0.0297 0.0297 0.0297 0.0297 0.0297 0.029
##  $ Viviendas              : num  0.12 0.12 0.12 0.12 0.12 ...
##  $ precio_medio_m2        : num  0.18 0.18 0.18 0.18 0.18 ...
##  $ Peso_vivienda          : int  2 2 2 2 2 2 2 2 2 2 ...
##  $ RAISON_SOCIAL          : chr  "ALGECIREÑA DE MOTOR E INV., S.L." "ALGECIREÑA DE MOTOR E INV., S.L
##  $ RUE_SSOC               : chr  "Ctra. a Malaga, Km. 108" "Ctra. a Malaga, Km. 108" "Ctra. a Malaga
##  $ Edad_Conductor         : chr  "18 a 20 años" "21 a 24 años" "25 a 29 años" "30 a 34 años" ...
##  $ Numero de Conductores  : num  0.0132 0.0569 0.1086 0.1392 0.1706 ...
##  $ Antigüedad             : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ Anos_Antiguedad        : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ Numero_vehiculos_parque: int  0 0 0 0 0 0 0 0 0 0 ...
##  $ Cluster_GamaPotencia   : chr  "cluster_1_GamaPotencia" "cluster_1_GamaPotencia" "cluster_1_GamaPo
##  $ Cluster_Antiguedad     : chr  "cluster_1_Antiguedad" "cluster_1_Antiguedad" "cluster_1_Antiguedad
##  $ Cluster_Edad           : chr  "cluster_3_Edad" "cluster_3_Edad" "cluster_3_Edad" "cluster_3_Edad"
```

```
head(file_codificado)
```

```
##   Carburante Potencia Servicio_Vehiculo Actividad_Vehiculo       GAMA
## 1          1       60               B00                  D UTILITARIO
## 2          1       60               B00                  D UTILITARIO
## 3          1       60               B00                  D UTILITARIO
## 4          1       60               B00                  D UTILITARIO
## 5          1       60               B00                  D UTILITARIO
## 6          1       60               B00                  D UTILITARIO
##   Unidades_Matriculadas Localidad_definitiva Provincia_definitiva Codigo_Postal
## 1                     0            ALGECIRAS                CADIZ        0.0297
## 2                     0            ALGECIRAS                CADIZ        0.0297
## 3                     0            ALGECIRAS                CADIZ        0.0297
## 4                     0            ALGECIRAS                CADIZ        0.0297
## 5                     0            ALGECIRAS                CADIZ        0.0297
## 6                     0            ALGECIRAS                CADIZ        0.0297
##   Viviendas precio_medio_m2 Peso_vivienda                  RAISON_SOCIAL
## 1    0.1201          0.1799             2 ALGECIREÑA DE MOTOR E INV., S.L.
## 2    0.1201          0.1799             2 ALGECIREÑA DE MOTOR E INV., S.L.
```

```
## 3    0.1201          0.1799             2 ALGECIREÑA DE MOTOR E INV., S.L.
## 4    0.1201          0.1799             2 ALGECIREÑA DE MOTOR E INV., S.L.
## 5    0.1201          0.1799             2 ALGECIREÑA DE MOTOR E INV., S.L.
## 6    0.1201          0.1799             2 ALGECIREÑA DE MOTOR E INV., S.L.
##                  RUE_SSOC Edad_Conductor Numero de Conductores Antigüedad
## 1 Ctra. a Malaga, Km. 108   18 a 20 años                0.0132          0
## 2 Ctra. a Malaga, Km. 108   21 a 24 años                0.0569          0
## 3 Ctra. a Malaga, Km. 108   25 a 29 años                0.1086          0
## 4 Ctra. a Malaga, Km. 108   30 a 34 años                0.1392          0
## 5 Ctra. a Malaga, Km. 108   35 a 39 años                0.1706          0
## 6 Ctra. a Malaga, Km. 108   40 a 44 años                0.1577          0
##   Anos_Antiguedad Numero_vehiculos_parque   Cluster_GamaPotencia
## 1               0                       0 cluster_1_GamaPotencia
## 2               0                       0 cluster_1_GamaPotencia
## 3               0                       0 cluster_1_GamaPotencia
## 4               0                       0 cluster_1_GamaPotencia
## 5               0                       0 cluster_1_GamaPotencia
## 6               0                       0 cluster_1_GamaPotencia
##     Cluster_Antiguedad   Cluster_Edad
## 1 cluster_1_Antiguedad cluster_3_Edad
## 2 cluster_1_Antiguedad cluster_3_Edad
## 3 cluster_1_Antiguedad cluster_3_Edad
## 4 cluster_1_Antiguedad cluster_3_Edad
## 5 cluster_1_Antiguedad cluster_3_Edad
## 6 cluster_1_Antiguedad cluster_3_Edad
```

```
tail(file_codificado)
```

```
##    Carburante Potencia Servicio_Vehiculo Actividad_Vehiculo       GAMA
## 78          1       60               B00                  D UTILITARIO
## 79          1       60               B00                  D UTILITARIO
## 80          1       60               B00                  D UTILITARIO
## 81          1       60               B00                  D UTILITARIO
## 82          1       60               B00                  D UTILITARIO
## 83          1       60               B00                  D UTILITARIO
##    Unidades_Matriculadas    Localidad_definitiva Provincia_definitiva
## 78                     0 CHICLANA DE LA FRONTERA                CADIZ
## 79                     0 CHICLANA DE LA FRONTERA                CADIZ
## 80                     0 CHICLANA DE LA FRONTERA                CADIZ
## 81                     0 CHICLANA DE LA FRONTERA                CADIZ
## 82                     0 CHICLANA DE LA FRONTERA                CADIZ
## 83                     0 CHICLANA DE LA FRONTERA                CADIZ
##    Codigo_Postal Viviendas precio_medio_m2 Peso_vivienda          RAISON_SOCIAL
## 78         0.028    0.1132          0.4255             3       RAMON HOYO, S.L.
## 79         0.028    0.1132          0.4255             3 TALLERES COLCHÓN, S.L.
## 80         0.028    0.1132          0.4255             3 TALLERES COLCHÓN, S.L.
## 81         0.028    0.1132          0.4255             3 TALLERES COLCHÓN, S.L.
## 82         0.028    0.1132          0.4255             3 TALLERES COLCHÓN, S.L.
## 83         0.028    0.1132          0.4255             3 TALLERES COLCHÓN, S.L.
##                   RUE_SSOC Edad_Conductor Numero de Conductores Antigüedad
## 78 AVDA. REYES CATOLICOS, 5 Más de 74 años                0.0098          0
## 79               Caraza, 33   18 a 20 años                0.0099          0
## 80               Caraza, 33   21 a 24 años                0.0321          0
## 81               Caraza, 33   25 a 29 años                0.0793          0
## 82               Caraza, 33   30 a 34 años                0.0946          0
```

```
## 83               Caraza, 33   35 a 39 años                0.1150          0
##    Anos_Antiguedad Numero_vehiculos_parque   Cluster_GamaPotencia
## 78               0                       0 cluster_1_GamaPotencia
## 79               0                       0 cluster_1_GamaPotencia
## 80               0                       0 cluster_1_GamaPotencia
## 81               0                       0 cluster_1_GamaPotencia
## 82               0                       0 cluster_1_GamaPotencia
## 83               0                       0 cluster_1_GamaPotencia
##      Cluster_Antiguedad   Cluster_Edad
## 78 cluster_6_Antiguedad cluster_3_Edad
## 79 cluster_1_Antiguedad cluster_3_Edad
## 80 cluster_1_Antiguedad cluster_3_Edad
## 81 cluster_1_Antiguedad cluster_3_Edad
## 82 cluster_1_Antiguedad cluster_3_Edad
## 83 cluster_1_Antiguedad cluster_3_Edad
```

```
summary(file_codificado)
```

```
##    Carburante    Potencia  Servicio_Vehiculo  Actividad_Vehiculo
##  Min.   :1    Min.   :60   Length:83          Length:83
##  1st Qu.:1    1st Qu.:60   Class :character   Class :character
##  Median :1    Median :60   Mode  :character   Mode  :character
##  Mean   :1    Mean   :60
##  3rd Qu.:1    3rd Qu.:60
##  Max.   :1    Max.   :60
##      GAMA           Unidades_Matriculadas Localidad_definitiva
##  Length:83          Min.   :0             Length:83
##  Class :character   1st Qu.:0             Class :character
##  Mode  :character   Median :0             Mode  :character
##                     Mean   :0
##                     3rd Qu.:0
##                     Max.   :0
##  Provincia_definitiva Codigo_Postal      Viviendas      precio_medio_m2
##  Length:83            Min.   :0.0280   Min.   :0.1132   Min.   :0.1799
##  Class :character     1st Qu.:0.0280   1st Qu.:0.1132   1st Qu.:0.1799
##  Mode  :character     Median :0.0280   Median :0.1132   Median :0.4255
##                       Mean   :0.1003   Mean   :0.1487   Mean   :0.3761
##                       3rd Qu.:0.0297   3rd Qu.:0.1201   3rd Qu.:0.4255
##                       Max.   :0.4860   Max.   :0.3258   Max.   :0.6015
##  Peso_vivienda   RAISON_SOCIAL        RUE_SSOC         Edad_Conductor
##  Min.   :2.000   Length:83          Length:83          Length:83
##  1st Qu.:2.000   Class :character   Class :character   Class :character
##  Median :3.000   Mode  :character   Mode  :character   Mode  :character
##  Mean   :2.843
##  3rd Qu.:3.000
##  Max.   :4.000
##  Numero de Conductores   Antigüedad Anos_Antiguedad Numero_vehiculos_parque
##  Min.   :0.00740       Min.   :0    Min.   :0       Min.   :0
##  1st Qu.:0.02720       1st Qu.:0    1st Qu.:0       1st Qu.:0
##  Median :0.06250       Median :0    Median :0       Median :0
##  Mean   :0.06731       Mean   :0    Mean   :0       Mean   :0
##  3rd Qu.:0.10035       3rd Qu.:0    3rd Qu.:0       3rd Qu.:0
##  Max.   :0.17060       Max.   :0    Max.   :0       Max.   :0
##  Cluster_GamaPotencia Cluster_Antiguedad Cluster_Edad
##  Length:83            Length:83          Length:83
```

```
##  Class :character     Class :character   Class :character
##  Mode  :character     Mode  :character   Mode  :character
##
##
##
```

Podemos observar con el str que tenemos 22 variables con un total de 83 observaciones. COn el summary vemos las distntas medidas de cada variable. COmo muchas son characters, son 0. Con el head y tail nos hacemos una idea de los valores de cada variable y algunos ejemplos. COmo por ejemplo la edad del conductor.

7. Fichero JSON iris_json.json

7.1. Importar el fichero iris_json.json

Importamos los valores con la funcion read_json y usamos otra vez el , simplifyVector = T para que se ponga correctamente en formato tabla.

```
iris_json <- read_json("./data/iris_json.json", simplifyVector = T)
```

Ahora paaso a usar fromJSON. Visualizando los dos dataframes no veo inguna diferencia. Parece que almacena la misma información. La unica diferencia parece ser que si no usas el simplify vector, el read_json te devuelve un formato de texto de R, en vez de un dataframe.

```
iris_from_json <- fromJSON("./data/iris_json.json")
```

```
str(iris_json)
```

```
## 'data.frame':    150 obs. of  5 variables:
##  $ Sepal.Length: num  5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
##  $ Sepal.Width : num  3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1 ...
##  $ Petal.Length: num  1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ...
##  $ Petal.Width : num  0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ...
##  $ Species     : chr  "setosa" "setosa" "setosa" "setosa" ...
```

```
head(iris_json)
```

```
##   Sepal.Length Sepal.Width Petal.Length Petal.Width Species
## 1          5.1         3.5          1.4         0.2  setosa
## 2          4.9         3.0          1.4         0.2  setosa
## 3          4.7         3.2          1.3         0.2  setosa
## 4          4.6         3.1          1.5         0.2  setosa
## 5          5.0         3.6          1.4         0.2  setosa
## 6          5.4         3.9          1.7         0.4  setosa
```

```
tail(iris_json)
```

```
##     Sepal.Length Sepal.Width Petal.Length Petal.Width   Species
## 145          6.7         3.3          5.7         2.5 virginica
## 146          6.7         3.0          5.2         2.3 virginica
## 147          6.3         2.5          5.0         1.9 virginica
## 148          6.5         3.0          5.2         2.0 virginica
## 149          6.2         3.4          5.4         2.3 virginica
## 150          5.9         3.0          5.1         1.8 virginica
```

```
summary(iris_json)
```

```
##   Sepal.Length    Sepal.Width     Petal.Length    Petal.Width
##  Min.   :4.300   Min.   :2.000   Min.   :1.000   Min.   :0.100
```

```
##  1st Qu.:5.100   1st Qu.:2.800   1st Qu.:1.600   1st Qu.:0.300
##  Median :5.800   Median :3.000   Median :4.350   Median :1.300
##  Mean   :5.843   Mean   :3.057   Mean   :3.758   Mean   :1.199
##  3rd Qu.:6.400   3rd Qu.:3.300   3rd Qu.:5.100   3rd Qu.:1.800
##  Max.   :7.900   Max.   :4.400   Max.   :6.900   Max.   :2.500
##    Species
##  Length:150
##  Class :character
##  Mode  :character
##
##
##
```

Podemos observar que tenemos 5 variables y 150 observaciones. Vemos como tenemos medidadas de tamaño de los petalos y sepalos, y además el tipo de especie al que corresponde cada muestra.

7.2. 8.3 exportar datos en formato JSON

Podemos observar que si no usamos el pretty, nos crea un json en una línea. Esto es poco lejible para un humano pero alomejor no nos importa si es solo para usar con scripts.

```
library(jsonlite)


load("./data/results/iris.RData")

write_json(iris, "./data/iris.json", pretty = TRUE)

write_json(iris, "./data/iris_feo.json", pretty = F)
```